

Proposta de Trabalho de Conclusão de Curso

Título da Proposta:

Aluno (s):

Telefone (s):

E-mail (s):

Orientador (a):

1. Introdução

O cenário de e-sports (esportes eletrônicos) tem apresentado um crescimento significativo nas últimas décadas, alcançando 532 milhões de espectadores em 2022 (Eschart, 2026; Tang *et al*, 2023). Dentre esses, MOBA (*Multiplayer Online Battle Arena*) destaca-se, tendo League of Legends (LoL) como um dos títulos mais populares, com eventos que alcançam até 6,3 milhões de espectadores simultâneos em plataformas online (STATISTA, 2023).

No jogo, duas equipes competem em um campo de batalha virtual, com o objetivo de derrotar o Nexus inimigo, sendo essa a condição que determina a vitória da partida. Para isso, jogadores precisam acumular recursos e fortalecer seus campeões, que são os personagens controlados durante o jogo.

Como é característico do gênero, LoL tem uma curva íngreme de aprendizado devido à grande quantidade de escolhas e variáveis envolvidas, o que pode desincentivar jogadores iniciantes (RIJNDERS; WALLNER; BERNHAUPT, 2022). Esse fator é intensificado por se tratar de uma atividade multijogador, uma vez que o desempenho individual de um jogador pode ser significativamente influenciado pelo comportamento de seus aliados e adversários (JALOVAARA, 2024).

Nesse contexto, métricas tradicionais amplamente utilizadas, como número de abates, mortes e assistências, mostram-se insuficientes para representar adequadamente o impacto real de um jogador no resultado da partida (MAYMIN, 2021). Essas métricas desconsideram o contexto em que as ações ocorrem, podendo levar a interpretações equivocadas sobre o desempenho individual.

Portanto, torna-se necessário o desenvolvimento de abordagens que permitam analisar o desempenho de jogadores de maneira mais contextualizada, considerando o momento da partida em que cada ação ocorre. Este trabalho propõe a utilização de modelos de aprendizado de máquina, treinados sobre dados temporais de partidas de League of Legends, para estimar empiricamente a importância de diferentes métricas de estado de jogo em distintas fases da partida, substituindo a atribuição manual de pesos por valores derivados diretamente dos dados.

2. Objetivos

2.1 Objetivo geral:

Desenvolver uma abordagem baseada em aprendizado de máquina para estimar empiricamente a importância contextual de métricas comportamentais de desempenho ao longo das fases de uma partida de League of Legends, considerando jogadores da função mid lane, no elo Ouro da região BR1, visando auxiliar jogadores na análise do próprio desempenho.

2.2 Objetivos Específicos:

1. Coletar e processar dados temporais (timeline) de partidas de League of Legends, restritos à função mid lane e ao elo Ouro da região BR1, segmentados em fases de jogo.
2. Treinar modelos de aprendizado de máquina para predição da probabilidade de vitória a partir de métricas comportamentais do jogador em cada fase da partida.
3. Aplicar técnicas de interpretabilidade de modelos (SHAP) para extrair a importância relativa de cada métrica dentro de sua respectiva fase, derivando pesos contextuais de forma empírica.
4. Desenvolver um método de comparação entre o desempenho de um jogador e a distribuição de jogadores de função e elo equivalentes, ponderada pelas importâncias obtidas, fornecendo uma análise contextualizada das métricas em que o jogador apresenta maior desvio em relação à mediana, priorizadas conforme seu impacto estimado na fase correspondente.

3. Justificativa

O crescimento do cenário de e-sports, em especial de League of Legends, tem gerado uma demanda crescente por ferramentas de análise de desempenho acessíveis a jogadores amadores(achar a referência).

Contudo, as métricas tradicionalmente disponíveis nas interfaces do jogo e em plataformas de terceiros, como número de abates, mortes e assistências, carecem de contextualização temporal, tratando ações ocorridas em momentos distintos da partida com o mesmo peso, o que pode levar a interpretações equivocadas do desempenho individual.

Abordagens baseadas em dados já demonstraram valor significativo em esportes tradicionais, onde métricas derivadas estatisticamente substituíram avaliações subjetivas e revelaram padrões não intuitivos de desempenho(referência). A aplicação de metodologia equivalente a jogos competitivos representa uma extensão natural dessa tendência, com a vantagem de que ambientes digitais oferecem dados granulares e estruturados que raramente estão disponíveis em esportes físicos.

Este trabalho se justifica pela ausência de abordagens que combinem segmentação da partida em fases de jogo com derivação empírica de pesos por meio de modelos preditivos e técnicas de interpretabilidade. Ao substituir pesos definidos manualmente por importâncias

extraídas de dados reais, a abordagem proposta reduz a dependência de julgamentos subjetivos na ponderação das métricas, oferecendo uma alternativa fundamentada empiricamente para a análise contextualizada de desempenho em jogos do gênero MOBA.

Além da contribuição metodológica, espera-se que os resultados tenham valor prático direto: ao identificar não apenas em quais aspectos um jogador está abaixo do esperado, mas também o quanto cada um desses aspectos historicamente impacta o resultado da partida em sua respectiva fase, a abordagem proposta favorece uma análise mais direcionada do próprio desempenho, permitindo, por exemplo, que um jogador identifique se suas maiores dificuldades estão concentradas no início, meio ou fim de jogo, e priorize seu aprendizado de acordo com o impacto estimado de cada métrica.

4. Metodologia

A metodologia proposta está organizada em cinco etapas principais: coleta de dados, segmentação das partidas em fases de jogo, modelagem preditiva, análise de interpretabilidade e desenvolvimento de um método de comparação de desempenho.

1. **Coleta de dados.** Os dados serão obtidos por meio da API oficial da Riot Games, em conformidade com os termos de uso da plataforma para desenvolvedores, restritos a partidas da fila ranqueada solo/duo (queue_id 420), de jogadores na função mid lane e classificados no nível de elo Ouro, na região BR1. A coleta será realizada por meio de um algoritmo de busca em largura (BFS), partindo de um jogador semente e expandindo a busca através dos participantes das partidas encontradas, de modo a obter uma amostra com maior diversidade de jogadores. Reconhece-se que esta estratégia de amostragem pode introduzir viés associado à rede social do jogador semente, motivo pelo qual a amostra final será verificada quanto à sua distribuição em variáveis como duração da partida, taxa de vitória agregada e diversidade de campeões utilizados. Serão extraídos tanto os metadados da partida quanto a linha do tempo (match timeline), que fornece o estado do jogo em intervalos curtos ao longo de toda a partida. Apenas dados agregados das partidas serão armazenados, sem identificadores pessoais dos jogadores.
2. **Segmentação em fases.** Em vez de utilizar marcos temporais fixos, a divisão das partidas em fases (early, mid e late game) será baseada em eventos de jogo: o fim da fase early é demarcado pela destruição da primeira torre, e o fim da fase mid pelo primeiro abate do Baron Nashor. Em partidas nas quais esses eventos não ocorrem dentro de uma janela razoável, serão utilizados marcos temporais de segurança (14 e 25 minutos, respectivamente) como critério de desempate. Essa abordagem híbrida prioriza a consistência do estado de jogo sobre a consistência temporal estrita, refletindo de forma mais fiel o ritmo real de cada partida.
3. **Seleção de variáveis.** As variáveis utilizadas para modelagem serão restritas a métricas comportamentais, ou seja, indicadores diretamente associados a ações controláveis pelo

jogador, como CS por minuto, pontuação de visão por minuto, participação em abates, mortes por minuto e proximidade a objetivos. Métricas de estado agregado da partida, como diferença de ouro e de experiência entre as equipes, serão deliberadamente excluídas do conjunto de variáveis preditoras, uma vez que representam consequências do desempenho mais do que ações específicas do jogador, e sua inclusão tornaria as importâncias derivadas pouco informativas para a finalidade de análise individual proposta neste trabalho.

4. **Modelagem preditiva.** Para cada fase, será treinado um modelo de classificação binária (gradient boosting, via XGBoost) com o objetivo de prever a probabilidade de vitória a partir das métricas comportamentais daquela fase. O treinamento de modelos separados por fase, em vez de um único modelo com todas as variáveis, permite isolar a contribuição de cada fase de forma independente. A divisão entre conjuntos de treino e teste será realizada ao nível de jogador (group split por PUUID), de modo que nenhum jogador apareça simultaneamente nos dois conjuntos, evitando que o modelo aprenda padrões individuais em vez de padrões generalizáveis. O desempenho dos modelos será avaliado por AUC, e modelos que não atingirem um patamar mínimo de discriminação ($AUC \geq 0,65$) terão suas importâncias reportadas com ressalvas, dado que a confiabilidade da análise interpretativa depende da qualidade da predição subjacente.
5. **Análise de interpretabilidade.** Sobre os modelos treinados, será aplicada a técnica SHAP (SHapley Additive exPlanations), que estima a contribuição marginal de cada variável para a predição do modelo. A média dos valores absolutos de SHAP por variável, calculada sobre o conjunto de teste, será utilizada como medida de importância relativa de cada métrica dentro de sua respectiva fase. As comparações de importância serão restritas ao escopo intra-fase, ou seja, entre métricas de uma mesma fase, evitando interpretações enganosas que poderiam surgir da comparação direta entre valores de SHAP gerados por modelos distintos.
6. **Comparação de desempenho.** Por fim, será desenvolvido um método que compara o desempenho de um jogador em uma partida específica com a distribuição de jogadores de função e elo equivalentes, ponderando os desvios observados pelas importâncias obtidas via SHAP. O resultado é um conjunto de métricas comportamentais priorizadas conforme seu impacto estimado na fase correspondente, fornecendo uma base para a análise contextualizada do desempenho individual.
7. **Confirmar se as predições funcionam em um conjunto**

As etapas serão implementadas em Python, utilizando as bibliotecas pandas para manipulação de dados, XGBoost para modelagem preditiva e SHAP para interpretabilidade.

5. Cronograma

- Elaborar um cronograma de atividades previstas para o desenvolvimento do trabalho.

Atividades	Meses											
	0 1	0 2	0 3	0 4	0 5	0 6	0 7	0 8	0 9	1 0	1 1	1 2
Revisão Bibliográfica												
Definição de escopo e coleta de dados												
Pré-processamento e segmentação das partidas												
Treinamento e validação dos modelos preditivos												
Análise de interpretabilidade (SHAP)												
Desenvolvimento do método de comparação de desempenho												
Avaliação e testes												
Escrita do TCC												
Revisão final e preparação da defesa												

6. Referências

- Inserir as referências utilizadas, lembrando que todas devem ter sido citadas no texto.