

UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

PAULO ADRIANO LUPEPSA MAIA

TÍTULO PROVISÓRIO

PONTA GROSSA

2026

PAULO ADRIANO LUPEPSA MAIA

TÍTULO PROVISÓRIO

Placeholder title

Trabalho de Conclusão de Curso de Graduação apresentado como requisito para obtenção do título de Bacharel em Ciência da Computação, da Universidade Tecnológica Federal do Paraná (UTFPR).

Orientador(a): Prof. Dr. Richard Duarte Ribeiro.

Coorientador(a): Prof. Dr. Vinícius Camargo Andrade.

PONTA GROSSA

2026



[4.0 Internacional](https://creativecommons.org/licenses/by/4.0/)

Esta licença permite compartilhamento, remixe, adaptação e criação a partir do trabalho, mesmo para fins comerciais, desde que sejam atribuídos créditos ao(s) autor(es). Conteúdos elaborados por terceiros, citados e referenciados nesta obra não são cobertos pela licença.

PAULO ADRIANO LUPEPSA MAIA

TÍTULO PROVISÓRIO

Trabalho de Conclusão de Curso de Graduação
apresentado como requisito para obtenção do título
de Bacharel em Ciência da Computação, da
Universidade Tecnológica Federal do Paraná
(UTFPR).

Orientador(a): Prof. Dr. Richard Duarte Ribeiro.

Coorientador(a): Prof. Dr. Vinícius Camargo
Andrade.

Data de aprovação: 24/Junho/2026

Richard Duarte Ribeiro
Doutor em Ciência da Computação
Universidade Tecnológica Federal do Paraná

André Koscianski
Doutor em Ciência da Computação
Universidade Tecnológica Federal do Paraná

Simone de Almeida
Doutora em Engenharia da Produção
Universidade Tecnológica Federal do Paraná

PONTA GROSSA

2026

RESUMO

O resumo deve ressaltar de forma sucinta o conteúdo do trabalho, incluindo justificativa, objetivos, metodologia, resultados e conclusão. Deve ser redigido em um único parágrafo, justificado, contendo de 150 **até 500 palavras**. **Evitar incluir citações, fórmulas, equações e símbolos** no resumo. As palavras-chave e as *keywords* são grafadas em inicial minúscula quando não forem nome próprio ou nome científico e separados por ponto e vírgula.

Palavras-chave: palavra 1; palavra 2; palavra 3; palavra 4.

ABSTRACT

Seguir o mesmo padrão do resumo, com a tradução do texto do resumo para a língua estrangeira (língua inglesa).

Keywords: word 1; word 2; word 3; word 4.

LISTA DE TABELAS

Tabela 1: Legenda de símbolos.....	19
------------------------------------	----

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
AHP	Processo Analítico Hierárquico
API	Interface de Programação de Aplicações
AUC	Área sob a curva ROC
BFS	Busca em largura
CS	<i>Creep Score</i>
LoL	<i>League of Legends</i>
MOBA	<i>Multiplayer Online Battle Arena</i>
NBR	Norma Brasileira
PUUID	<i>Player Universally Unique Identifier</i>
SHAP	<i>SHapley Additive exPlanations</i>
UTFPR	Universidade Tecnológica Federal do Paraná

LISTA DE SÍMBOLOS

g	Função explicativa que aproxima o modelo original sendo retratado.
z'	Vetor de alocação dos atributos, cada elemento contém um valor binário representando a presença ou ausência do respectivo atributo.
φ_0	Predição do modelo para o vetor de alocação vazio ($z' = 0$), igual ao valor esperado sobre os dados de fundo.
φ_i	Valor SHAP do atributo representado pelo elemento “ i ” de z' para essa predição.
z'_i	Valor binário contido no elemento “ i ” do vetor de alocação z' .
M	Quantidade total de atributos contidos em z' .

SUMÁRIO

1 INTRODUÇÃO.....	13
2 REFERENCIAL TEÓRICO.....	17
2.1 Interpretabilidade.....	17
3 DESENVOLVIMENTO.....	20
3.1 Regras gerais de apresentação.....	20
3.2 Margens.....	20
3.3 Espaçamento.....	20
3.4 Ilustrações.....	20
3.5 Tabelas.....	20
3.6 Citações.....	20
3.6.1 Tipos de citações.....	20
3.6.2 Indicação de responsabilidade.....	21
4 CONCLUSÃO (OU CONSIDERAÇÕES FINAIS).....	21
REFERÊNCIAS.....	22
APÊNDICE 1 - Questionário de pesquisa.....	25
APÊNDICE 2 - Roteiro da entrevista.....	27
APÊNDICE 3 - Abreviaturas dos meses do ano.....	29
anexo 1 - Lei n. 9.610, de 19 de fevereiro de 1998.....	31

1 INTRODUÇÃO

O cenário de e-sports (esportes eletrônicos) tem apresentado um crescimento significativo nas últimas décadas, alcançando 532 milhões de espectadores em 2022 (NEWZOO, 2022). Dentre esses, MOBA (*Multiplayer Online Battle Arena*) destaca-se, tendo *League of Legends* (LoL) como um dos títulos mais populares, com eventos que alcançam até 6,9 milhões de espectadores simultâneos em plataformas online (ESPORTS CHARTS, 2026).

No jogo, duas equipes competem em um campo de batalha virtual, com o objetivo de derrotar o *Nexus* inimigo, sendo essa a condição que determina a vitória da partida. Para isso, jogadores precisam acumular recursos e fortalecer seus campeões, que são os personagens controlados durante o jogo.

Como é característico do gênero, LoL tem uma curva íngreme de aprendizado devido à grande quantidade de escolhas e variáveis envolvidas, o que pode desincentivar jogadores iniciantes (RIJNDERS; WALLNER; BERNHAUPT, 2022). Esse fator é intensificado por se tratar de uma atividade multijogador, uma vez que o desempenho individual de um jogador pode ser significativamente influenciado pelo comportamento de seus aliados e adversários (JALOVAARA, 2024).

Nesse contexto, métricas tradicionais amplamente utilizadas, como número de abates, mortes e assistências, mostram-se insuficientes para representar adequadamente o impacto real de um jogador no resultado da partida (MAYMIN, 2021). Essas métricas desconsideram o contexto em que as ações ocorrem, podendo levar a interpretações equivocadas sobre o desempenho individual.

Portanto, torna-se necessário o desenvolvimento de abordagens que permitam analisar o desempenho de jogadores de maneira mais contextualizada, considerando o momento da partida em que cada ação ocorre. Este trabalho propõe a utilização de modelos de aprendizado de máquina, treinados sobre dados temporais de partidas de *League of Legends*, para estimar empiricamente a importância de diferentes métricas comportamentais em distintas fases da partida, substituindo a atribuição manual de pesos por valores derivados diretamente dos dados.

A metodologia proposta está organizada em cinco etapas principais: coleta de dados, segmentação das partidas em fases de jogo, modelagem preditiva, análise de interpretabilidade e desenvolvimento de um método de comparação de desempenho.

1. **Coleta de dados.** Os dados serão obtidos por meio da API oficial da Riot Games *MATCH-V5*¹, em conformidade com os termos de uso da plataforma para desenvolvedores, restritos a partidas da fila ranqueada solo/duo (*queue_id* 420), de jogadores na função mid lane e classificados no nível de elo Ouro, na região BR1. A coleta será realizada por meio de um algoritmo de busca em largura (BFS)², partindo de um jogador semente e expandindo a busca através dos participantes das partidas encontradas, de modo a obter uma amostra com maior diversidade de jogadores. Reconhece-se que esta estratégia de amostragem pode introduzir viés associado à rede social do jogador semente, motivo pelo qual a amostra final será verificada quanto à sua distribuição em variáveis como duração da partida, taxa de vitória agregada e diversidade de campeões utilizados. Serão extraídos tanto os metadados da partida quanto a linha do tempo (*match timeline*), que fornece o estado do jogo em intervalos curtos ao longo de toda a partida. Apenas dados agregados das partidas serão armazenados, sem identificadores pessoais dos jogadores.
2. **Segmentação em fases.** Em vez de utilizar marcos temporais fixos, a divisão das partidas em fases (*early*, *mid* e *late game*) será baseada em eventos de jogo: o fim da fase *early* é demarcado pela destruição da primeira torre, e o fim da fase *mid* pelo primeiro abate do Barão Na'shor. Em partidas nas quais esses eventos não ocorrem dentro de uma janela razoável, serão utilizados marcos temporais de segurança (14 e 25 minutos, respectivamente) como critério de desempate. Essa abordagem híbrida prioriza a consistência do estado de jogo sobre a consistência temporal estrita, refletindo de forma mais fiel o ritmo real de cada partida.
3. **Seleção de variáveis.** As variáveis utilizadas para modelagem serão restritas a métricas comportamentais, ou seja, indicadores diretamente associados a ações controláveis pelo jogador, como CS³ por minuto, pontuação de visão por minuto, participação em abates, mortes por minuto e proximidade a objetivos. Métricas de estado agregado da partida, como diferença de ouro e de experiência entre as equipes, serão deliberadamente excluídas do conjunto de variáveis preditoras, uma vez que representam consequências do desempenho

¹Disponível em <https://developer.riotgames.com/apis#match-v5>.

²Disponível em <https://github.com/Blizzeq/league-of-legends-data-collector>.

³*Creep Score*: O contador individual de abate de inimigos denominados *Minions* que concedem recursos ao jogador.

mais do que ações específicas do jogador, e sua inclusão tornaria as importâncias derivadas pouco informativas para a finalidade de análise individual proposta neste trabalho.

4. **Modelagem preditiva.** Para cada fase, será treinado um modelo de classificação binária (*gradient boosting*, via XGBoost) com o objetivo de prever a probabilidade de vitória a partir das métricas comportamentais daquela fase. O treinamento de modelos separados por fase, em vez de um único modelo com todas as variáveis, permite isolar a contribuição de cada fase de forma independente. A divisão entre conjuntos de treino e teste será realizada ao nível de jogador (Divisão de grupo por PUUID), de modo que nenhum jogador apareça simultaneamente nos dois conjuntos, evitando que o modelo aprenda padrões individuais em vez de padrões generalizáveis. O desempenho dos modelos será avaliado por AUC, e modelos que não atingirem um patamar mínimo de discriminação ($AUC \geq 0,65$) terão suas importâncias reportadas com ressalvas, dado que a confiabilidade da análise interpretativa depende da qualidade da predição subjacente.
5. **Análise de interpretabilidade.** Sobre os modelos treinados, será aplicada a técnica SHAP (*SHapley Additive exPlanations*), que estima a contribuição marginal de cada variável para a predição do modelo. A média dos valores absolutos de SHAP por variável, calculada sobre o conjunto de teste, será utilizada como medida de importância relativa de cada métrica dentro de sua respectiva fase. As comparações de importância serão restritas ao escopo intra-fase, ou seja, entre métricas de uma mesma fase, evitando interpretações enganosas que poderiam surgir da comparação direta entre valores de SHAP gerados por modelos distintos.
6. **Comparação de desempenho.** Por fim, será desenvolvido um método que compara o desempenho de um jogador em uma partida específica com a distribuição de jogadores de função e elo equivalentes, ponderando os desvios observados pelas importâncias obtidas via SHAP. O resultado é um conjunto de métricas comportamentais priorizadas conforme seu impacto estimado na fase correspondente, fornecendo uma base para a análise contextualizada do desempenho individual.
7. Confirmar se as predições funcionam em um conjunto

As etapas serão implementadas em Python, utilizando as bibliotecas pandas para manipulação de dados, XGBoost para modelagem preditiva e SHAP para interpretabilidade.

2 REFERENCIAL TEÓRICO

Trabalhos anteriores sobre análise de performance em jogos do tipo MOBA convergiram na premissa de que o valor de uma ação dentro do jogo é contextual ao invés de fixo (MAYMIN, 2021; JALOVAARA, 2024), e estudos recentes têm aprofundado esse conceito de forma empírica.

Bahrololloomi *et al.* (2023) compararam a performance de diferentes jogadores de uma mesma posição, porém utilizando dados agregados de fim de partida, e uma métrica-alvo que serve de proxy para a performance em vez do resultado da partida.

Hojaji *et al.* (2025) obtiveram importância de atributos contextualizada em diferentes fases da partida através de SHAP, porém em nível de equipe ao invés de individual e escolhendo limiares de fases fixos em relação ao tempo de jogo.

Kamal *et al.* (2026) avaliaram métricas ao longo das fases temporais do jogo, porém definiram os pesos dos atributos de forma subjetiva, através de opiniões de especialistas revisadas em pares (AHP).

Perez *et al.* (2024) decompuseram a performance individual em partes, mas deixaram a análise em fases temporais explicitamente como trabalho futuro.

Nenhuma dessas obras combina (i) segmentação em fases baseada em eventos de jogo, (ii) conjunto de variáveis exclusivamente comportamentais, restringidas a ações controláveis pelo indivíduo, (iii) pesos distintos por fase, obtidos empiricamente através de SHAP, e (iv) um método que produz comparações de performance entre um indivíduo e outros jogadores de mesma posição e em um nível similar de habilidade, em diferentes fases de uma partida. Este trabalho aborda justamente essa interseção.

2.1 Interpretabilidade

Ferramentas de aprendizado de máquina têm sido uma alternativa popular para a resolução de problemas de classificação nas últimas décadas. Devido à sua característica de ponderação de diversos atributos, essas ferramentas são capazes de navegar em ambientes complexos descartando pouca informação.

A maleabilidade que as torna capaz de lidar com esses ambientes, porém, também resulta em uma característica de caixa preta, ocultando a lógica por trás do processo e dificultando sua interpretação conforme o aumento da sua complexidade.

Ferramentas menos opacas por sua vez, permitem melhor transparência de sua lógica, porém têm sua complexidade restringida, o que reduz sua capacidade de modelar situações mais complicadas em troca de maior rastreabilidade.

A interpretabilidade, então, surge como o grau de transparência com o qual se pode entender o funcionamento dessas ferramentas (MOLNAR, 2022).

Um modo de interpretar o funcionamento desse processo vem da teoria dos jogos; suponha que a predição é um jogo, no qual os atributos atuam como jogadores, contribuindo para produzir um resultado, como seria possível deduzir o quanto cada um dos participantes influenciou no resultado?

Shapley (1953) propôs o valor de Shapley, que distribui de forma justa a contribuição de cada jogador ao resultado, calculada como a média das contribuições marginais de um atributo, avaliada sobre todas as ordens possíveis de inclusão dos atributos. Essa distribuição é a única que satisfaz um conjunto de propriedades desejáveis, entre elas a eficiência, ou seja, a soma das contribuições individuais equivale exatamente ao resultado produzido .

A partir desse conceito, Lundberg e Lee (2017) transportaram o conceito de Shapley a partir da teoria dos jogos para a atribuição de atributos de aprendizado de máquina. Os autores propuseram o conceito de valor SHAP. O valor SHAP representa a única solução dentro da classe de métodos aditivos de atribuição, que satisfaz simultaneamente três propriedades: precisão local, ausência e consistência.

O valor SHAP é definido como um modelo aditivo de atribuição:

$$g(z') = \varphi_0 + \sum_{i=1}^M \varphi_i z'_i$$

Fórmula 1: Cálculo de $g(z')$

Em que:

Tabela 1: Legenda de símbolos

z'	Vetor de alocação dos atributos, cada elemento contém um valor binário representando a presença ou ausência do respectivo atributo.
g	Função explicativa que aproxima o modelo original sendo retratado.
φ_0	Predição do modelo para o vetor de alocação vazio ($z' = 0$), igual ao valor esperado sobre os dados de fundo.
M	Quantidade total de atributos contidos em z' .
φ_i	Valor SHAP do atributo representado pelo elemento “ i ” de z' para essa predição.
z'_i	Valor binário contido no elemento “ i ” do vetor de alocação z' .

A precisão local estabelece que, quando o vetor de alocação contém todos os atributos presentes ($z'_i = 1$ para todo i), configuração que representa a instância sendo explicada, a função explicativa reproduz a saída do modelo original, isto é, $g(z') = f(x)$, em que $f(x)$ é o valor predito pelo modelo original; essa igualdade entre a explicação e a predição original constitui a propriedade de precisão local.

Ausência define que um atributo ausente dentro da predição (ou seja, com $z'_i = 0$) deve ter contribuição igual a zero.

Consistência define que caso o modelo seja alterado de forma que a contribuição de um atributo aumente ou permaneça igual em todas as possíveis combinações de vetor de alocação, a sua contribuição não pode diminuir. É essa propriedade que fundamenta o uso da magnitude dos valores SHAP como medida de importância.

Um problema do cálculo dos valores SHAP pela definição geral é que sua demanda computacional é exponencial. Para obter todos os subconjuntos possíveis de atributos, a complexidade é $O(2^M)$, em que M é o número de atributos pertinentes. Essa característica torna a implementação impraticável para modelos que ingerem um número maior de atributos.

Lundberg *et al.* (2020) levaram em consideração a estrutura de árvores de decisão para propor o método TreeSHAP. Esse método adapta o cálculo dos valores SHAP para aproveitar essa estrutura.

O resultado esperado do modelo para um atributo ausente é obtido percorrendo ambos os ramos ponderados pela proporção de amostras que segue cada ramo. É essa abordagem que torna o gasto computacional polinomial e mantém a exatidão do resultado final.

A complexidade final do TreeSHAP é de $O(TLD^2)$, em que T representa o número de árvores, L representa o número máximo de folhas por árvore, e D representa a profundidade máxima por árvore. Como os modelos por fase deste trabalho são baseados em árvores (XGBoost), o TreeSHAP se aplica de forma exata e é o método adotado.

3 DESENVOLVIMENTO

3.1 Regras gerais de apresentação

3.2 Margens

3.3 Espaçamento

3.4 Ilustrações

3.5 Tabelas

3.6 Citações

3.6.1 Tipos de citações

3.6.2 Indicação de responsabilidade

4 CONCLUSÃO (OU CONSIDERAÇÕES FINAIS)

REFERÊNCIAS

BAHROLOLLOOMI, Farnod; KLONOWSKI, Fabio; SAUER, Sebastian; HORST, Robin; DÖRNER, Ralf. E-sports player performance metrics for predicting the outcome of League of Legends matches considering player roles. **SN Computer Science**, [s. l.], v. 4, art. 238, 2023. DOI: 10.1007/s42979-022-01660-6.

ESPORTS CHARTS. **League of Legends esports viewership and statistics**. [S. l.], c2026. Disponível em: <https://escharts.com/games/lol>. Acesso em: 24 jun. 2026.

HOJAJI, Fazilat; MCILROY, Robert E.; DUPUY, Antoine; PEDRONI, Gianpaolo; TOTH, Adam J.; CAMPBELL, Mark J. Deep learning techniques for identifying KPIs in League of Legends: win prediction, map navigation, and vision control. **Computers in Human Behavior Reports**, [s. l.], v. 19, art. 100718, 2025. DOI: 10.1016/j.chbr.2025.100718.

JALOVAARA, Perttu. Win probability estimation for strategic decision-making in esports. 2024. Dissertação (Mestrado) — Aalto University, Espoo, 2024. Disponível em: <https://aalto.fi/handle/123456789/131821>. Acesso em: 21 jun. 2026.

KAMAL, Ahmad Alif; MANSOR, Mohd. Asyraf; MOHD. KASIMUDDIN, Mohd. Shareduwan. Interpretable predictive framework for Mobile Legends match outcome using analytic hierarchy process weighted logistic regression variants. **Applied Soft Computing**, [s. l.], v. 187, art. 114301, 2026. DOI: 10.1016/j.asoc.2025.114301.

LUNDBERG, Scott M.; LEE, Su-In. A unified approach to interpreting model predictions. In: **Advances in Neural Information Processing Systems 30 (NIPS 2017)**. [S. l.]: Neural Information Processing Systems Foundation, 2017. p. 4768-4777.

LUNDBERG, Scott M.; ERION, Gabriel; CHEN, Hugh; DEGRAVE, Alex; PRUTKIN, Jordan M.; NAIR, Bala; KATZ, Ronit; HIMMELFARB, Jonathan; BANSAL, Nisha; LEE, Su-In. From local explanations to global understanding with explainable AI for trees. **Nature Machine Intelligence**, [s. l.], v. 2, n. 1, p. 56-67, jan. 2020. DOI: 10.1038/s42256-019-0138-9.

MAYMIN, Philip Z. Smart kills and worthless deaths: esports analytics for League of Legends. **Journal of Quantitative Analysis in Sports**, [s. l.], v. 17, n. 1, p. 11-27, 2021. DOI: 10.1515/jqas-2019-0096.

MOLNAR, Christoph. **Interpretable machine learning: a guide for making black box models explainable**. 2. ed. Munique: Edição do autor, 2022. ISBN 979-8-4114-6333-0.

NEWZOO. **Newzoo Global Esports & Live Streaming Market Report 2022**. [S. l.], 2022. Disponível em: <https://newzoo.com/resources/trend-reports/newzoo-global-esports-live-streaming-market-report-2022-free-version>. Acesso em: 24 jun.

PEREZ, Manuel; DIAZ, Cesar O.; SOLER, Pau; MIER, Aitor. Assessing player contributions in League of Legends matches: an analytical approach. **SN Computer Science**, [s. l.], v. 5, art. 968, 2024. DOI: 10.1007/s42979-024-03327-w.

RIJNDERS, Frans; WALLNER, Günter; BERNHAUPT, Regina. Live feedback for training through real-time data visualizations: a study with League of Legends.

Proceedings of the ACM on Human-Computer Interaction, New York, v. 6, n. CHI PLAY, art. 243, out. 2022. DOI: 10.1145/3549506.

SHAPLEY, L. S. A value for n-person games. In: KUHN, H.; TUCKER, A. (ed.).

Contributions to the theory of games: volume II. Princeton: Princeton University Press, 1953. p. 307-317. DOI: 10.1515/9781400881970-018.